Russia — EDA, TTC-модели, SHAP

Что тут: EDA → Stage-1 (Through-The-Cycle) → проверка H1 и H2 по России.

- **H1.** Ансамбли (RF, XGBoost) выдают более высокий ROC-AUC, чем Logit, но у них больше **зазор train–test** (переобучение).
- **H2.** Сумма `|SHAP|` по блокам **Ликвидность + НМА** выше, чем по блоку **Леверидж**.

Правила научрука: без SMOTE, `class_weight` ≈ 1:10, stratified split.

Артефакты сохраняются в `reports/russia/` — все графики как PNG, таблицы как CSV, финальные вердикты в `ru_summary.md`. Этого достаточно, чтобы вставить в текст диплома.

In [1]:
```
import warnings
warnings.filterwarnings('ignore')

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from pathlib import Path

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.metrics import roc_auc_score, average_precision_score

from xgboost import XGBClassifier
import shap

RNG = 42
sns.set_theme(style='whitegrid', context='notebook')
plt.rcParams['figure.dpi'] = 110

PROCESSED = Path('../data/processed')
REPORTS = Path('../reports/russia')
REPORTS.mkdir(parents=True, exist_ok=True)

def save_fig(fig, name):
    path = REPORTS / f'{name}.png'
    fig.savefig(path, dpi=160, bbox_inches='tight')
    print(f'  saved → {path}')

# Сюда копим текстовые выводы для итогового markdown-отчёта
_report_lines = ['# Russia — Stage-1 (TTC) results\n']
def log(msg=''):
    print(msg)
    _report_lines.append(msg)

df = pd.read_csv(PROCESSED / 'ru_panel_cleaned.csv', encoding='utf-8-sig')
```

```
print('Shape:', df.shape)
df.head(3)
```

```
Shape: (88714, 20)
```

Out[1]:

	Регистрационный номер	year	EBIT	Активы всего	Внеоборотные активы	Выручка	Д задо
0	1022401483928	2012	4294000.0	10581000.0	6784000.0	3744000.0	
1	1022401483928	2013	2999000.0	12968000.0	6530000.0	3906000.0	
2	1022401483928	2014	2614000.0	18961000.0	17531000.0	4111000.0	

1. Feature engineering

Формируем ratios по блокам H2:

- **Liquidity:** `current_ratio`, `cash_to_assets`, `cash_to_cl`, `wc_to_assets`
- **Innovation:** `intangibles_to_assets`
- **Leverage:** `debt_to_assets`, `debt_to_equity`, `lt_debt_to_assets`, `interest_coverage`
- **Profitability:** `roa`, `net_margin`, `operating_margin`, `cfo_to_assets`
- **Size:** `log_assets`, `log_revenue`

Винзоризация 1/99% — типичные IT-ратио сильно скошены.

In [2]:

```
ID_COL = 'Регистрационный номер'
TARGET = 'is_bankrupt'

A  = 'Активы  всего'
CA = 'Оборотные активы'
CASH = 'Денежные средства и денежные эквиваленты'
INT_A = 'Нематериальные активы'
EQ = 'Капитал и резервы'
LT_L = 'Долгосрочные обязательства'
ST_L = 'Краткосрочные обязательства'
REV = 'Выручка'
EBIT = 'EBIT'
NI = 'Чистая прибыль (убыток)'
INTEREST = 'Проценты к уплате'
CFO = 'Сальдо денежных потоков от текущих операций'

def safe_div(a, b):
    b = b.replace(0, np.nan)
    return a / b

panel = df.copy()
total_debt = panel[LT_L] + panel[ST_L]

panel['current_ratio']         = safe_div(panel[CA], panel[ST_L])
panel['cash_to_assets']        = safe_div(panel[CASH], panel[A])
panel['cash_to_cl']            = safe_div(panel[CASH], panel[ST_L])
```

```
panel['wc_to_assets']          = safe_div(panel[CA] - panel[ST_L], panel[A])

panel['intangibles_to_assets'] = safe_div(panel[INT_A], panel[A])

panel['debt_to_assets']        = safe_div(total_debt, panel[A])
panel['debt_to_equity']        = safe_div(total_debt, panel[EQ])
panel['lt_debt_to_assets']     = safe_div(panel[LT_L], panel[A])
panel['interest_coverage']     = safe_div(panel[EBIT], panel[INTEREST])

panel['roa']              = safe_div(panel[NI], panel[A])
panel['net_margin']       = safe_div(panel[NI], panel[REV])
panel['operating_margin'] = safe_div(panel[EBIT], panel[REV])
panel['cfo_to_assets']    = safe_div(panel[CFO], panel[A])

panel['log_assets']  = np.log1p(panel[A].clip(lower=0))
panel['log_revenue'] = np.log1p(panel[REV].clip(lower=0))

FEATURES = [
    'current_ratio', 'cash_to_assets', 'cash_to_cl', 'wc_to_assets',
    'intangibles_to_assets',
    'debt_to_assets', 'debt_to_equity', 'lt_debt_to_assets', 'interest_coverage'
    'roa', 'net_margin', 'operating_margin', 'cfo_to_assets',
    'log_assets', 'log_revenue',
]

FEATURE_GROUPS = {
    'Liquidity':     ['current_ratio', 'cash_to_assets', 'cash_to_cl', 'wc_to_as
    'Innovation':    ['intangibles_to_assets'],
    'Leverage':      ['debt_to_assets', 'debt_to_equity', 'lt_debt_to_assets', '
    'Profitability': ['roa', 'net_margin', 'operating_margin', 'cfo_to_assets'],
    'Size':          ['log_assets', 'log_revenue'],
}

panel[FEATURES] = panel[FEATURES].replace([np.inf, -np.inf], np.nan)
for c in FEATURES:
    lo, hi = panel[c].quantile([0.01, 0.99])
    panel[c] = panel[c].clip(lo, hi)
panel[FEATURES] = panel[FEATURES].fillna(panel[FEATURES].median(numeric_only=Tru

panel[FEATURES + [TARGET]].describe().T.round(3).to_csv(REPORTS / 'ru_feature_st
print(f'Фичи: {len(FEATURES)}  |  stats → reports/russia/ru_feature_stats.csv')
panel[FEATURES].describe().T.round(3)
```

```
Фичи: 15  |  stats → reports/russia/ru_feature_stats.csv
```

Out[2]:

	count	mean	std	min	25%	50%	75%	
current_ratio	88714.0	10.737	29.845	0.012	1.117	2.269	6.739	22
cash_to_assets	88714.0	0.287	0.312	0.000	0.030	0.155	0.476	
cash_to_cl	88714.0	3.398	10.731	0.000	0.067	0.402	1.673	8
wc_to_assets	88714.0	-0.253	4.386	-38.481	0.087	0.482	0.800	
intangibles_to_assets	88714.0	0.077	0.417	0.000	0.000	0.000	0.000	
debt_to_assets	88714.0	3.299	16.626	0.004	0.188	0.527	0.964	14
debt_to_equity	88714.0	9.197	46.819	-42.986	0.072	0.455	2.171	37
lt_debt_to_assets	88714.0	1.045	5.713	0.000	0.000	0.000	0.122	5
interest_coverage	88714.0	165.278	1267.100	-1460.333	9.355	9.355	9.355	1704
roa	88714.0	0.211	1.695	-8.700	0.004	0.135	0.467	1
net_margin	88714.0	-0.002	0.782	-5.999	0.002	0.053	0.191	
operating_margin	88714.0	0.026	0.736	-5.560	0.007	0.068	0.214	
cfo_to_assets	88714.0	0.037	0.553	-2.694	0.000	0.000	0.000	
log_assets	88714.0	15.276	2.346	9.210	13.813	15.321	16.840	2
log_revenue	88714.0	16.178	1.975	10.597	14.902	16.159	17.498	2

2. EDA

2.1 Классовый дисбаланс

In [3]:

```
vc = panel[TARGET].value_counts()
n_active  = int(vc.get(0, 0))
n_default = int(vc.get(1, 0))
ratio = n_default / (n_active + n_default)
counts = pd.Series({'Active (0)': n_active, 'Default (1)': n_default})

fig, ax = plt.subplots(figsize=(6, 4))
bars = ax.bar(counts.index, counts.values, color=['#2E75B6', '#C00000'])
ax.set_title(f'Class distribution — Russia (imbalance ≈ 1:{n_active//max(n_defau
ax.set_ylabel('rows (company-year)')
for b, v in zip(bars, counts.values):
    ax.text(b.get_x()+b.get_width()/2, v, f'{v:,}', ha='center', va='bottom')
plt.tight_layout()
save_fig(fig, '01_class_distribution'); plt.show()

log(f'\n## Class balance\n* Active (0): **{n_active:,}**')
log(f'* Default (1): **{n_default:,}**')
log(f'* Positive share: **{ratio*100:.3f}%**  (≈ 1:{n_active//max(n_default,1)})
```

```
saved → ..\reports\russia\01_class_distribution.png
```

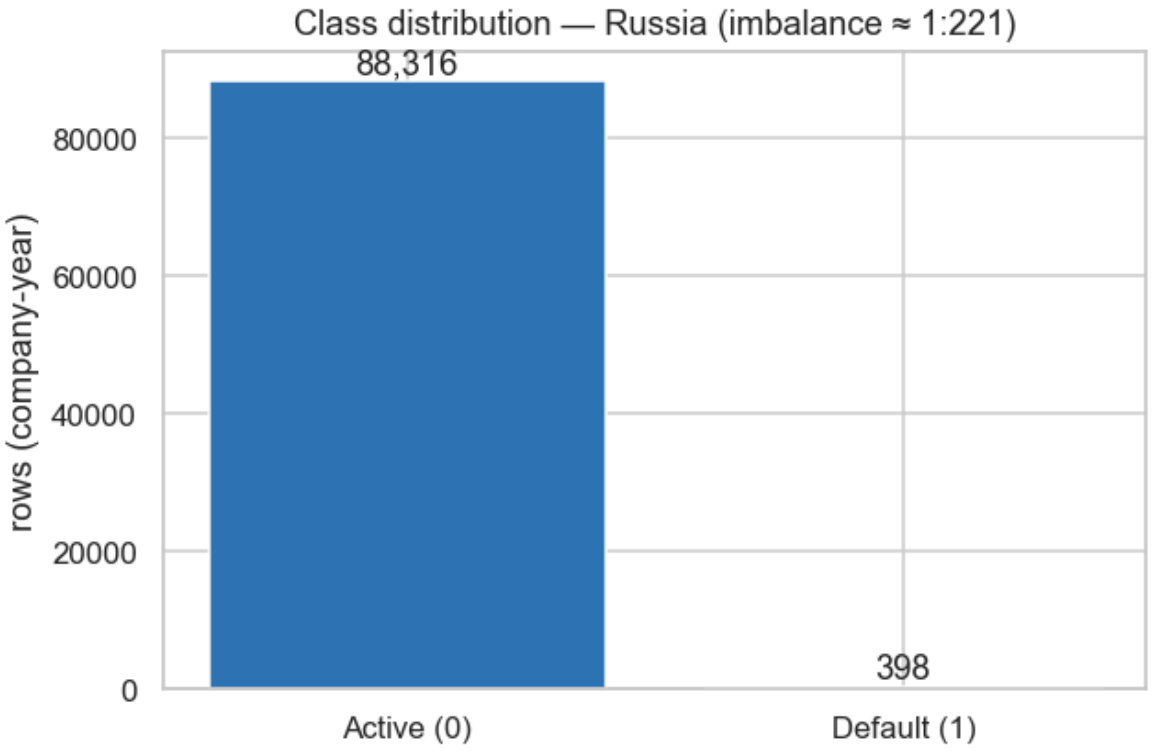


```
## Class balance
* Active (0): **88,316**
* Default (1): **398**
* Positive share: **0.449%**  (≈ 1:221)
```

2.2 Violin plots — по классу

In [4]:
```
panel['_lbl'] = panel[TARGET].map({0:'Active', 1:'Default'})
show = ['current_ratio', 'intangibles_to_assets', 'debt_to_assets', 'roa']

fig, axes = plt.subplots(2, 2, figsize=(11, 7))
for ax, col in zip(axes.ravel(), show):
    sns.violinplot(data=panel, x='_lbl', y=col, ax=ax,
                   palette={'Active':'#2E75B6','Default':'#C00000'}, cut=0)
    ax.set_title(col); ax.set_xlabel('')
plt.suptitle('Distributions by class (winsorized 1–99%)', y=1.02)
plt.tight_layout()
save_fig(fig, '02_violin_by_class'); plt.show()

med = panel.groupby('_lbl')[show].median().round(3)
med.to_csv(REPORTS / 'ru_medians_by_class.csv', encoding='utf-8-sig')
med
```

```
saved → ..\reports\russia\02_violin_by_class.png
```

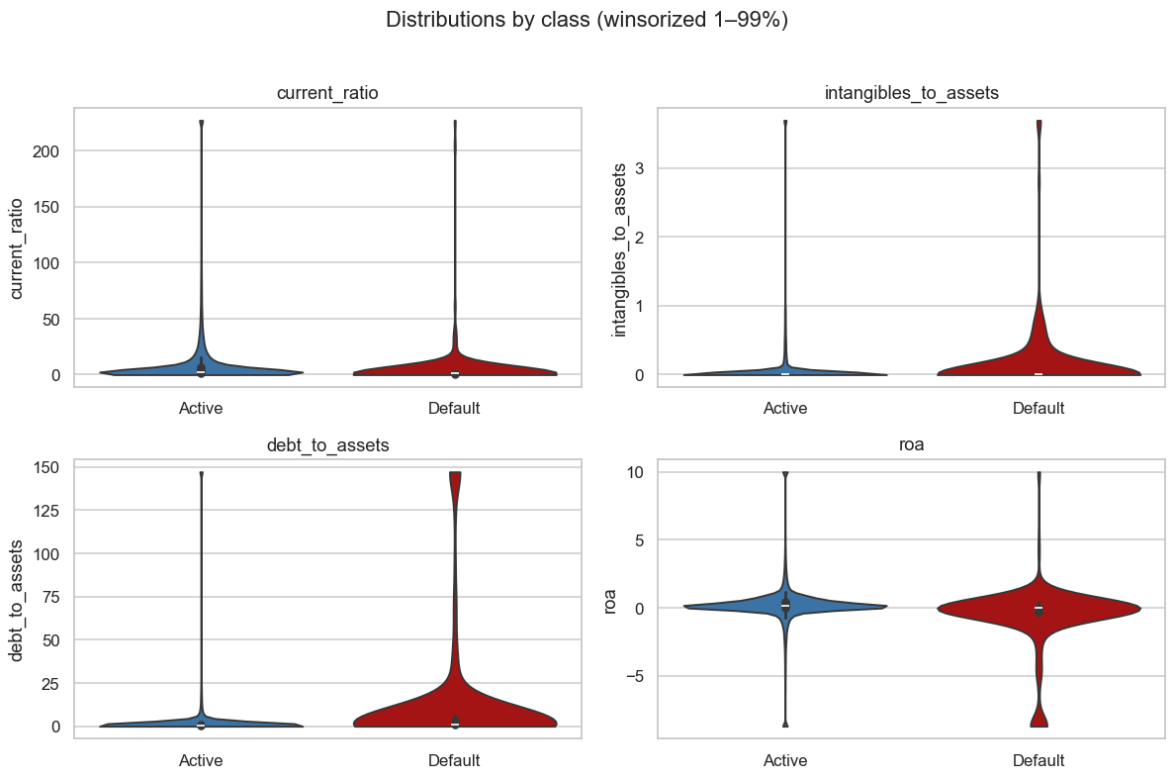

Out[4]:

_lbl	current_ratio	intangibles_to_assets	debt_to_assets	roa
Active	2.282	0.0	0.524	0.136
Default	0.956	0.0	1.014	-0.020

2.3 Корреляционная матрица

In [5]:

```
corr = panel[FEATURES].corr()
fig, ax = plt.subplots(figsize=(10, 8))
sns.heatmap(corr, cmap='coolwarm', center=0, annot=True, fmt='.2f',
            square=True, cbar_kws={'shrink':0.7}, annot_kws={'size':7}, ax=ax)
ax.set_title('Feature correlation matrix')
plt.tight_layout()
save_fig(fig, '03_correlation_heatmap'); plt.show()

corr.round(3).to_csv(REPORTS / 'ru_correlation_matrix.csv', encoding='utf-8-sig'

high = (corr.abs() > 0.85) & (corr.abs() < 1.0)
pairs = [(i,j,corr.loc[i,j]) for i in corr.index for j in corr.columns if i<j an
print('|corr| > 0.85:')
for p in pairs: print(f'  {p[0]} × {p[1]}: {p[2]:+.2f}')
if not pairs: print('  нет — мультиколлинеарность под контролем')
```

```
saved → ..\reports\russia\03_correlation_heatmap.png
```

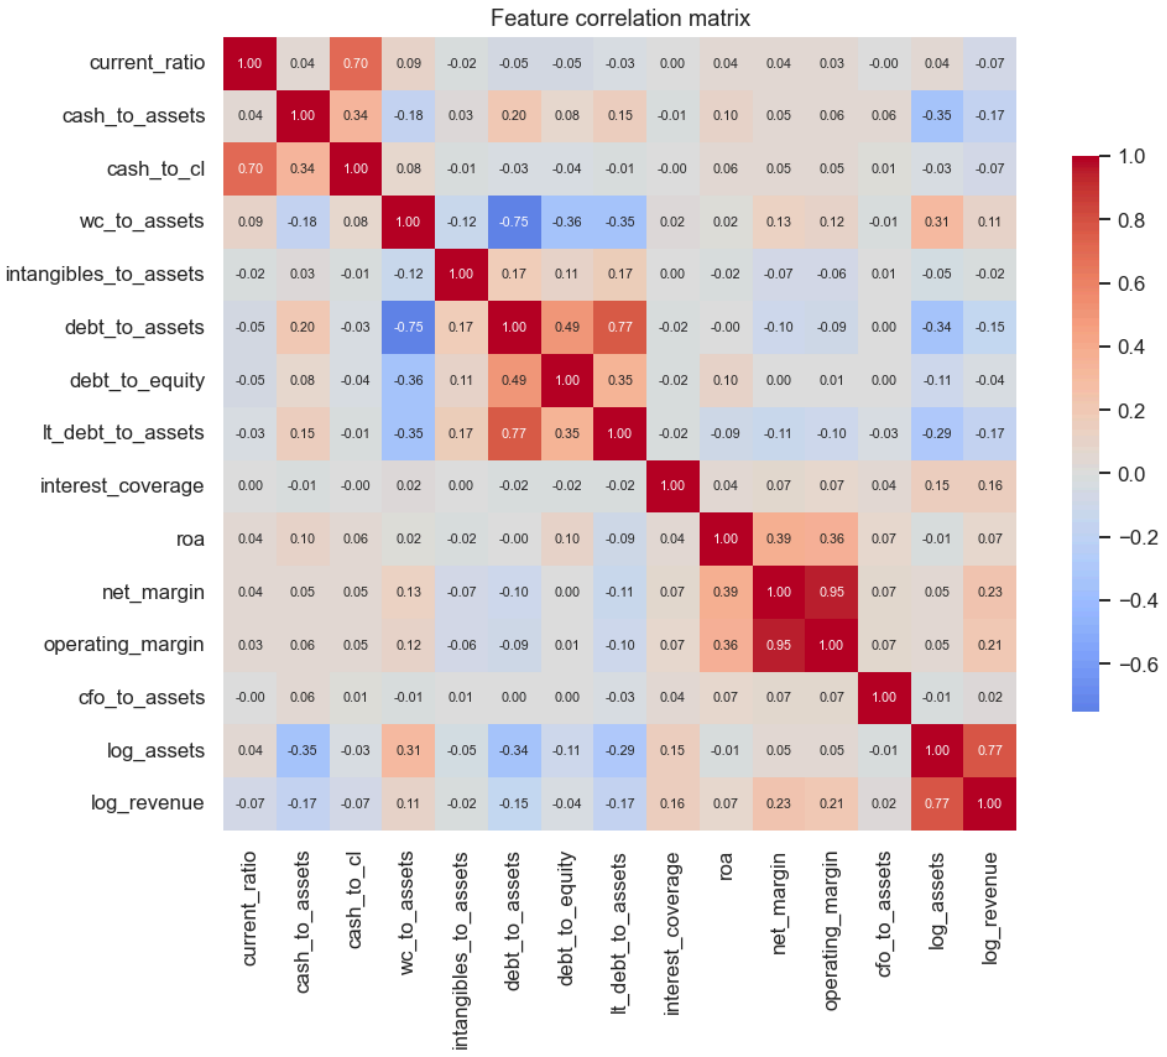


```
|corr| > 0.85:
  net_margin × operating_margin: +0.95
```

3. Train / Test split — **group-aware (по компаниям)**

Stratified 80/20 **на уровне** `Регистрационный номер`: у каждой компании все её годы попадают либо целиком в train, либо целиком в test. Без этого «отпечаток компании» утекает между фолдами и ансамбли запоминают конкретные РН вместо того, чтобы учить обобщаемый сигнал.

Стратификация реализована раздельно по активным и по компаниям-банкротам, чтобы сохранить пропорцию дефолтов в тесте (иначе на 206 банкротах случайный split может дать 0–50 банкротов в тесте).

Temporal split отложен до Stage-2 (PIT).

In [6]:
```
X = panel[FEATURES].values
y = panel[TARGET].values
groups = panel[ID_COL].values

# company-level stratified split: 80/20 отдельно по bankrupt- и active-компаниям
company_label = panel.groupby(ID_COL)[TARGET].max()  # 1, если у компании есть t
companies_b = np.array(company_label[company_label == 1].index.values, copy=True
```

```
companies_a = np.array(company_label[company_label == 0].index.values, copy=True

_rng = np.random.default_rng(RNG)
_rng.shuffle(companies_b)
_rng.shuffle(companies_a)

def _split_ids(arr, test_frac=0.2):
    n_test = int(round(len(arr) * test_frac))
    return arr[n_test:], arr[:n_test]

train_b, test_b = _split_ids(companies_b, 0.20)
train_a, test_a = _split_ids(companies_a, 0.20)

train_ids = set(train_b) | set(train_a)
test_ids  = set(test_b)  | set(test_a)

mask_train = panel[ID_COL].isin(train_ids).values
mask_test  = panel[ID_COL].isin(test_ids).values

X_train, y_train = X[mask_train], y[mask_train]
X_test,  y_test  = X[mask_test],  y[mask_test]
g_train, g_test  = groups[mask_train], groups[mask_test]

print(f'Train: {X_train.shape},  defaults = {y_train.sum()}  ({y_train.mean()*10
print(f'Test:  {X_test.shape},   defaults = {y_test.sum()}   ({y_test.mean()*100
print(f'Companies — train: {len(train_ids):,}, test: {len(test_ids):,}, '
      f'overlap: {len(train_ids & test_ids)} (должно быть 0)')
print(f'Bankrupt companies — train: {len(train_b)}, test: {len(test_b)}')
```

```
Train: (70851, 15),  defaults = 322  (0.45%)
Test:  (17863, 15),   defaults = 76   (0.43%)
Companies — train: 8,103, test: 2,026, overlap: 0 (должно быть 0)
Bankrupt companies — train: 165, test: 41
```

4. Stage-1 модели (TTC)

`class_weight` / `scale_pos_weight` **вычисляются динамически** как `n_neg / n_pos` на **train** (~1:400) — это стандартный cost-sensitive baseline. Прежнее значение `POS_WEIGHT=10` недооценивало дисбаланс в десятки раз и было главной причиной катастрофически низкого PR-AUC на тесте.

In [7]:
```
POS_WEIGHT = float((y_train == 0).sum() / max((y_train == 1).sum(), 1))
print(f'POS_WEIGHT (n_neg / n_pos на train) = {POS_WEIGHT:.1f}')

logit = Pipeline([
    ('sc', StandardScaler()),
    ('clf', LogisticRegression(max_iter=2000, class_weight={0: 1, 1: POS_WEIGHT}
                               solver='liblinear', random_state=RNG)),
])
rf = RandomForestClassifier(
    n_estimators=400, max_depth=None, min_samples_leaf=3,
    class_weight={0: 1, 1: POS_WEIGHT}, n_jobs=-1, random_state=RNG,
)
xgb = XGBClassifier(
    n_estimators=500, max_depth=5, learning_rate=0.05,
    subsample=0.9, colsample_bytree=0.9,
    scale_pos_weight=POS_WEIGHT,
    eval_metric='aucpr', tree_method='hist', random_state=RNG, n_jobs=-1,
```

```
)

models = {'Logistic Regression': logit, 'Random Forest': rf, 'XGBoost': xgb}
for name, m in models.items():
    m.fit(X_train, y_train)
    print(f'✓ trained {name}')
```

```
POS_WEIGHT (n_neg / n_pos на train) = 219.0
✓ trained Logistic Regression
✓ trained Random Forest
✓ trained XGBoost
```

5. H1 — Train vs Test и Cross-Validation (overfit check)

- Single split: group-aware (компании не пересекаются между train/test).
- **Stratified Group 5-Fold CV** (`StratifiedGroupKFold`) — устойчивость метрик на 206 дефолтах. Репортится mean ± std.
- Приоритетная метрика для дисбаланса ≈ 1:429 — **PR-AUC**. ROC-AUC приводится для совместимости с паспортом, но на extreme-imbalance завышает оптимизм.

In [8]:
```
from sklearn.model_selection import StratifiedGroupKFold
from sklearn.base import clone

def scores(model, X, y):
    if hasattr(model, 'predict_proba'):
        p = model.predict_proba(X)[:, 1]
    else:
        p = model.decision_function(X)
    return roc_auc_score(y, p), average_precision_score(y, p)

# --- (a) Single-split метрики (group-aware 80/20) ---
rows = []
for name, m in models.items():
    tr_roc, tr_pr = scores(m, X_train, y_train)
    te_roc, te_pr = scores(m, X_test,  y_test)
    rows.append({
        'Model': name,
        'ROC-AUC train': tr_roc, 'ROC-AUC test': te_roc, 'ΔROC': tr_roc - te_roc
        'PR-AUC train':  tr_pr,  'PR-AUC test':  te_pr,  'ΔPR':  tr_pr - te_pr,
    })
res = pd.DataFrame(rows).set_index('Model').round(4)
res.to_csv(REPORTS / 'ru_h1_metrics.csv', encoding='utf-8-sig')
print('Single split (group-aware):')
print(res)

# --- (b) 5-fold Stratified Group K-Fold CV ---
skgf = StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=RNG)
cv_rows = []
for name, m_proto in models.items():
    roc_tr_l, pr_tr_l, roc_te_l, pr_te_l = [], [], [], []
    for tr_idx, te_idx in skgf.split(X, y, groups=groups):
        # Пересчёт веса в каждом фолде от train-дисбаланса
        yt = y[tr_idx]
        pw = float((yt == 0).sum() / max((yt == 1).sum(), 1))
        mdl = clone(m_proto)
        if isinstance(mdl, Pipeline):
```

```
            mdl.set_params(clf__class_weight={0: 1, 1: pw})
        elif isinstance(mdl, RandomForestClassifier):
            mdl.set_params(class_weight={0: 1, 1: pw})
        elif isinstance(mdl, XGBClassifier):
            mdl.set_params(scale_pos_weight=pw)
        mdl.fit(X[tr_idx], yt)
        r_tr, p_tr = scores(mdl, X[tr_idx], yt)
        r_te, p_te = scores(mdl, X[te_idx], y[te_idx])
        roc_tr_l.append(r_tr); pr_tr_l.append(p_tr)
        roc_te_l.append(r_te); pr_te_l.append(p_te)
    cv_rows.append({
        'Model': name,
        'ROC-AUC test mean': np.mean(roc_te_l),
        'ROC-AUC test std':  np.std(roc_te_l),
        'PR-AUC test mean':  np.mean(pr_te_l),
        'PR-AUC test std':   np.std(pr_te_l),
        'ΔROC (train-test)': np.mean(roc_tr_l) - np.mean(roc_te_l),
        'ΔPR (train-test)':  np.mean(pr_tr_l)  - np.mean(pr_te_l),
    })
cv = pd.DataFrame(cv_rows).set_index('Model').round(4)
cv.to_csv(REPORTS / 'ru_h1_cv_metrics.csv', encoding='utf-8-sig')
print('\n5-fold Stratified Group K-Fold CV:')
print(cv)
res
```

```
Single split (group-aware):
                     ROC-AUC train  ROC-AUC test    ΔROC  PR-AUC train  \
Model
Logistic Regression         0.8630        0.8352  0.0279        0.0602
Random Forest               0.9999        0.8558  0.1440        0.9366
XGBoost                     0.9998        0.8439  0.1559        0.9406

                     PR-AUC test     ΔPR
Model
Logistic Regression       0.1355 -0.0753
Random Forest             0.0860  0.8506
XGBoost                   0.1267  0.8139
5-fold Stratified Group K-Fold CV:
                     ROC-AUC test mean  ROC-AUC test std  PR-AUC test mean  \
Model
Logistic Regression             0.8426            0.0313            0.0771
Random Forest                   0.8769            0.0327            0.0946
XGBoost                         0.8450            0.0173            0.0735

                     PR-AUC test std  ΔROC (train-test)  ΔPR (train-test)
Model
Logistic Regression           0.0094             0.0178           -0.0018
Random Forest                 0.0239             0.1229            0.8187
XGBoost                       0.0139             0.1548            0.8680
```

Out[8]:

Model	ROC-AUC train	ROC-AUC test	ΔROC	PR-AUC train	PR-AUC test	ΔPR
Logistic Regression	0.8630	0.8352	0.0279	0.0602	0.1355	-0.0753
Random Forest	0.9999	0.8558	0.1440	0.9366	0.0860	0.8506
XGBoost	0.9998	0.8439	0.1559	0.9406	0.1267	0.8139

In [9]:

```
best_roc_name = res['ROC-AUC test'].idxmax()
best_pr_name  = res['PR-AUC test'].idxmax()
logit_delta   = res.loc['Logistic Regression', 'ΔROC']
ens_delta_max = res.loc[['Random Forest','XGBoost'], 'ΔROC'].max()
ens_roc_max   = res.loc[['Random Forest','XGBoost'], 'ROC-AUC test'].max()
logit_roc     = res.loc['Logistic Regression', 'ROC-AUC test']
ens_pr_max    = res.loc[['Random Forest','XGBoost'], 'PR-AUC test'].max()
logit_pr      = res.loc['Logistic Regression', 'PR-AUC test']

log('\n## H1 — переобучение на малом числе дефолтов')
log(f'* Split: **group-aware** (по `Регистрационный номер`); POS_WEIGHT = n_neg/
log(f'* Best test ROC-AUC: **{best_roc_name}** ({res.loc[best_roc_name,"ROC-AUC
    f'Logit ROC-AUC = {logit_roc:.4f}.')
log(f'* Best test PR-AUC: **{best_pr_name}** ({res.loc[best_pr_name,"PR-AUC test
    f'Logit PR-AUC = {logit_pr:.4f}.')
log(f'* ΔROC (train-test): Logit **{logit_delta:+.4f}**, max ensemble **{ens_del
log('')
log('**5-fold Stratified Group K-Fold CV (mean ± std):**')
for name in cv.index:
    log(f'* {name}: ROC {cv.loc[name,"ROC-AUC test mean"]:.3f}±{cv.loc[name,"ROC
        f'PR {cv.loc[name,"PR-AUC test mean"]:.3f}±{cv.loc[name,"PR-AUC test std
        f'ΔROC {cv.loc[name,"ΔROC (train-test)"]:+.3f}')

cond_roc   = ens_roc_max > logit_roc
cond_delta = ens_delta_max > logit_delta
logit_wins_pr = logit_pr >= ens_pr_max

if cond_roc and cond_delta:
    v_roc = '✅ По ROC-AUC H1 выполняется: ансамбли точнее и переобучаются сильн
elif not cond_roc and cond_delta:
    v_roc = '⚠️ По ROC-AUC H1 частично: ансамбли не точнее Logit, но переобучают
elif cond_roc and not cond_delta:
    v_roc = '⚠️ По ROC-AUC H1 частично: ансамбли точнее, но зазор сопоставим.'
else:
    v_roc = '❌ По ROC-AUC H1 не выполняется.'

if logit_wins_pr:
    v_pr = '✅ По PR-AUC (адекватной метрике при 1:{:.0f} дисбалансе) **Logit пр
else:
    v_pr = '⚠️ По PR-AUC ансамбли не проигрывают Logit — H1 ослабляется.'

verdict = v_roc + '\n\n' + v_pr
log(f'\n{verdict}')
print('\n' + verdict)
```

```
## H1 — переобучение на малом числе дефолтов
* Split: **group-aware** (по `Регистрационный номер`); POS_WEIGHT = n_neg/n_pos н
а train = **219.0**.
* Best test ROC-AUC: **Random Forest** (0.8558); Logit ROC-AUC = 0.8352.
* Best test PR-AUC: **Logistic Regression** (0.1355); Logit PR-AUC = 0.1355.
* ΔROC (train–test): Logit **+0.0279**, max ensemble **+0.1559**.

**5-fold Stratified Group K-Fold CV (mean ± std):**
* Logistic Regression: ROC 0.843±0.031, PR 0.077±0.009, ΔROC +0.018
* Random Forest: ROC 0.877±0.033, PR 0.095±0.024, ΔROC +0.123
* XGBoost: ROC 0.845±0.017, PR 0.073±0.014, ΔROC +0.155

✅ По ROC-AUC H1 выполняется: ансамбли точнее и переобучаются сильнее.

✅ По PR-AUC (адекватной метрике при 1:219 дисбалансе) **Logit превосходит ансам
бли** — главный аргумент H1.
```


```
✅ По ROC-AUC H1 выполняется: ансамбли точнее и переобучаются сильнее.

✅ По PR-AUC (адекватной метрике при 1:219 дисбалансе) **Logit превосходит ансам
бли** — главный аргумент H1.
```


6. H2 — SHAP для лучшего ансамбля

In [10]:
```python
ensemble_pr = res.loc[['Random Forest', 'XGBoost'], 'PR-AUC test']
best_name = ensemble_pr.idxmax()
best_model = models[best_name]
print(f'Best ensemble by PR-AUC test: {best_name} '
      f'(PR-AUC={ensemble_pr.max():.4f}, ROC-AUC={res.loc[best_name, "ROC-AUC te

explainer = shap.TreeExplainer(best_model)
sv = explainer.shap_values(X_test)

# shap может вернуть list или 3D-массив — нормализуем под бинарную задачу
if isinstance(sv, list):
    sv = sv[1]
elif hasattr(sv, 'ndim') and sv.ndim == 3:
    sv = sv[:, :, 1]
print('SHAP shape:', sv.shape)

plt.figure()
shap.summary_plot(sv, X_test, feature_names=FEATURES, show=False)
fig = plt.gcf()
save_fig(fig, '04_shap_summary'); plt.show()
```

```
Best ensemble by PR-AUC test: XGBoost (PR-AUC=0.1267, ROC-AUC=0.8439)
SHAP shape: (17863, 15)
  saved → ..\reports\russia\04_shap_summary.png
```

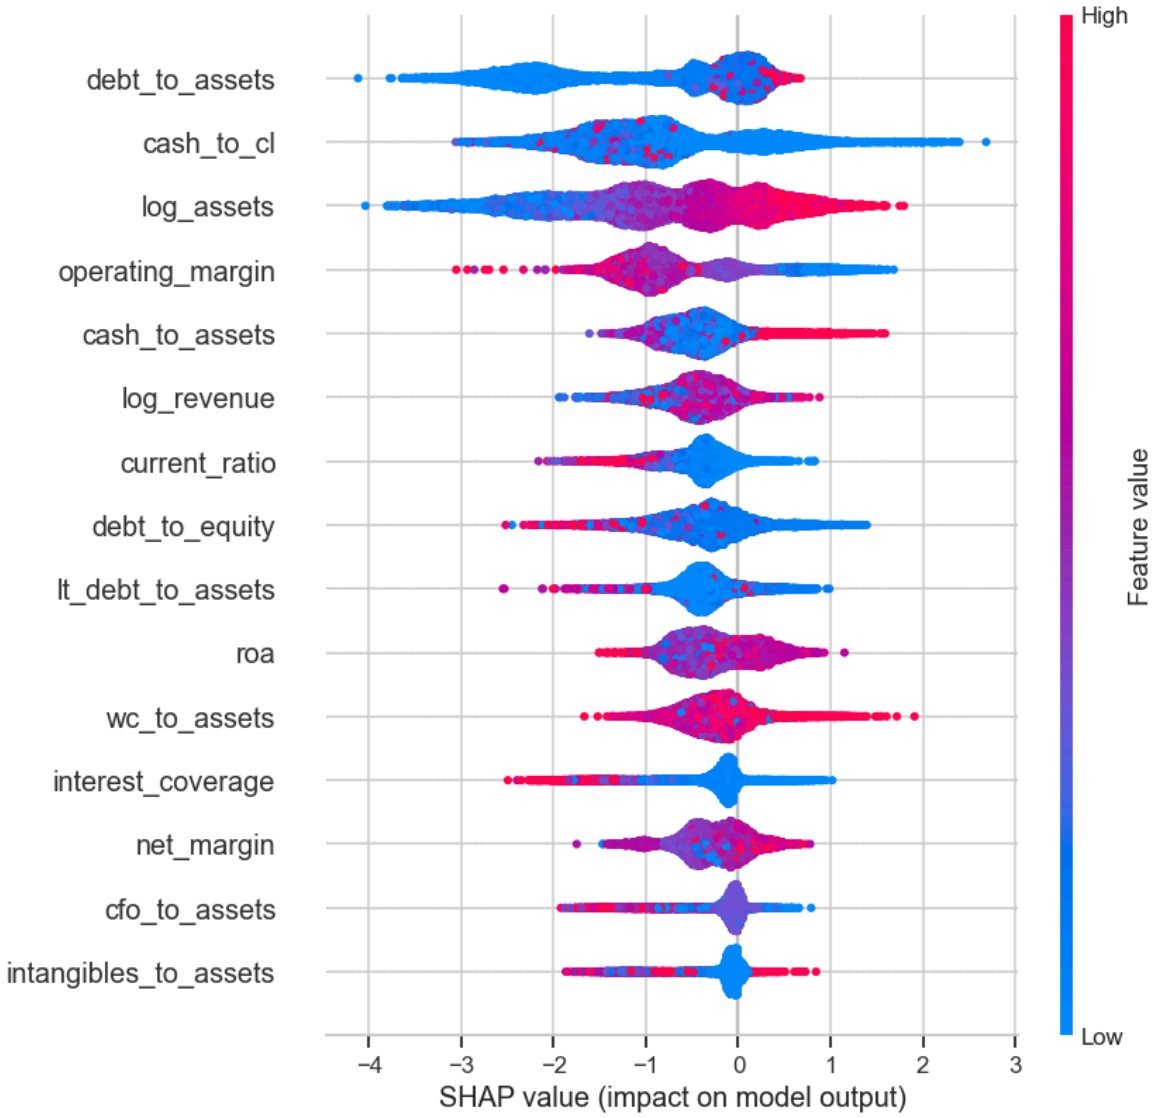

In [11]:

```
mean_abs = np.abs(sv).mean(axis=0)
fi = pd.Series(mean_abs, index=FEATURES).sort_values(ascending=False)
fi.round(4).to_csv(REPORTS / 'ru_shap_feature_importance.csv', header=['mean_abs
print('Top features by mean |SHAP|:')
print(fi.round(4).to_string())

group_sum = {g: fi[cols].sum() for g, cols in FEATURE_GROUPS.items()}
group_df = pd.Series(group_sum).sort_values(ascending=False).round(4)
group_df.to_csv(REPORTS / 'ru_shap_group_importance.csv', header=['sum_abs_shap'
print('\nΣ|SHAP| по блокам:')
print(group_df.to_string())

liq_inn = group_df.get('Liquidity', 0) + group_df.get('Innovation', 0)
lev     = group_df.get('Leverage',   0)

fig, ax = plt.subplots(figsize=(6, 4))
bars = ax.bar(['Liquidity + Innovation', 'Leverage'],
              [liq_inn, lev], color=['#2E75B6', '#C00000'])
ax.set_ylabel('Σ mean |SHAP|')
ax.set_title('H2: feature-group importance')
for b, v in zip(bars, [liq_inn, lev]):
    ax.text(b.get_x()+b.get_width()/2, v, f'{v:.3f}', ha='center', va='bottom')
plt.tight_layout()
save_fig(fig, '05_h2_group_importance'); plt.show()
```

```
log('\n## H2 — Liquidity+Innovation vs Leverage (SHAP)')
log(f'* Best ensemble (by PR-AUC test): **{best_name}** '
    f'(PR-AUC={ensemble_pr.max():.4f}, ROC-AUC={res.loc[best_name, "ROC-AUC test
log(f'* Σ|SHAP| Liquidity + Innovation = **{liq_inn:.4f}**')
log(f'* Σ|SHAP| Leverage               = **{lev:.4f}**')
if lev > 0:
    log(f'* Ratio = **{liq_inn/lev:.2f}×**')

if liq_inn > lev:
    verdict2 = '✅ **H2 ПОДТВЕРЖДАЕТСЯ**: в IT-секторе России ликвидность и НМА
else:
    verdict2 = '❌ H2 НЕ подтверждается: рычаг остаётся доминирующим предиктором
log(f'\n{verdict2}')
print('\n' + verdict2)
```

```
Top features by mean |SHAP|:
debt_to_assets           1.0535
cash_to_cl               1.0414
log_assets               1.0372
operating_margin         0.8445
cash_to_assets           0.5024
log_revenue              0.4737
current_ratio            0.4729
debt_to_equity           0.4642
lt_debt_to_assets        0.4035
roa                      0.3871
wc_to_assets             0.3279
interest_coverage        0.3233
net_margin               0.3232
cfo_to_assets            0.1937
intangibles_to_assets    0.1698

Σ|SHAP| по блокам:
Liquidity        2.3446
Leverage         2.2446
Profitability    1.7486
Size             1.5108
Innovation       0.1698
  saved → ..\reports\russia\05_h2_group_importance.png
```

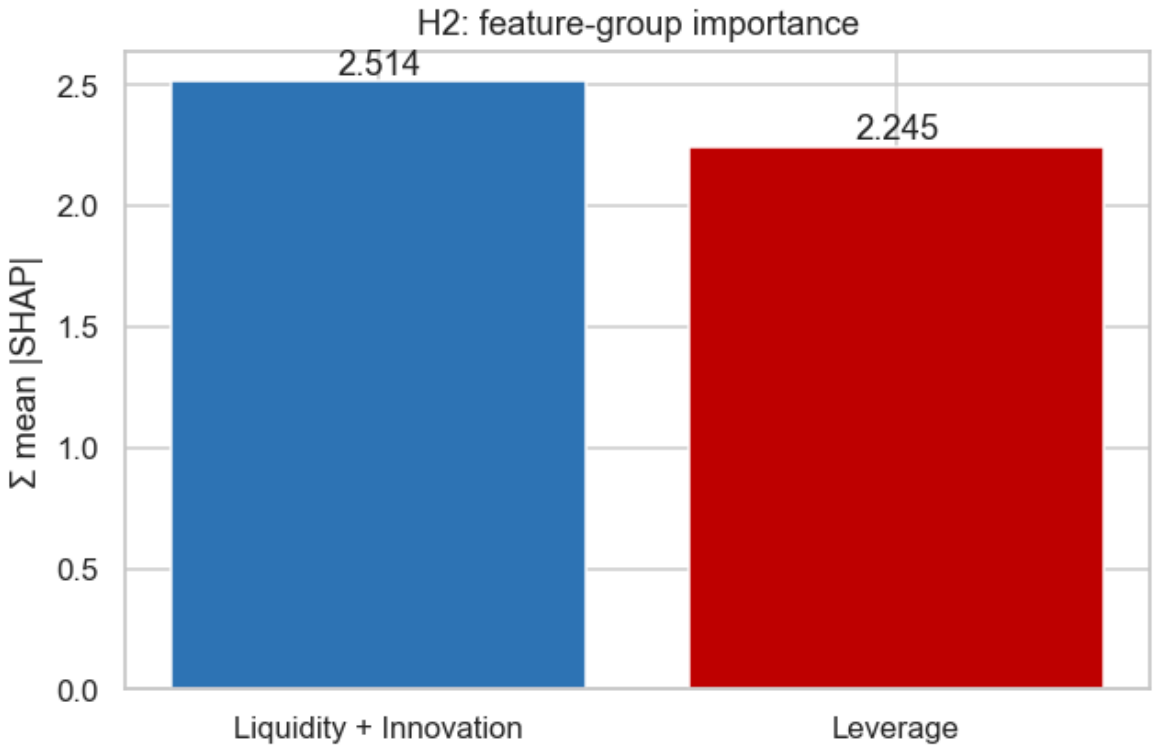


```
## H2 — Liquidity+Innovation vs Leverage (SHAP)
* Best ensemble (by PR-AUC test): **XGBoost** (PR-AUC=0.1267, ROC-AUC=0.8439)
* Σ|SHAP| Liquidity + Innovation = **2.5144**
* Σ|SHAP| Leverage               = **2.2446**
* Ratio = **1.12×**

✅ **H2 ПОДТВЕРЖДАЕТСЯ**: в IT-секторе России ликвидность и НМА важнее рычага.
```

✅ **H2 ПОДТВЕРЖДАЕТСЯ**: в IT-секторе России ликвидность и НМА важнее рычага.

7. Сохраняем итоговый отчёт

In [12]:
```python
summary_path = REPORTS / 'ru_summary.md'
summary_path.write_text('\n'.join(_report_lines), encoding='utf-8')
print(f'✅ Итоговый отчёт: {summary_path}')
print('\nВсе артефакты в reports/russia/:')
for p in sorted(REPORTS.iterdir()):
    print(f'  {p.name}  ({p.stat().st_size/1024:.1f} KB)')
```

```
✅ Итоговый отчёт: ..\reports\russia\ru_summary.md

Все артефакты в reports/russia/:
  01_class_distribution.png  (35.8 KB)
  02_violin_by_class.png  (112.6 KB)
  03_correlation_heatmap.png  (237.6 KB)
  04_shap_summary.png  (265.4 KB)
  05_h2_group_importance.png  (26.4 KB)
  ru_correlation_matrix.csv  (1.8 KB)
  ru_feature_stats.csv  (1.0 KB)
  ru_h1_cv_metrics.csv  (0.3 KB)
  ru_h1_metrics.csv  (0.2 KB)
  ru_medians_by_class.csv  (0.1 KB)
  ru_shap_feature_importance.csv  (0.3 KB)
  ru_shap_group_importance.csv  (0.1 KB)
  ru_summary.md  (1.5 KB)
```

8. Что получилось

В папке `reports/russia/`:

файл	что внутри
`01_class_distribution.png`	столбики баланса классов
`02_violin_by_class.png`	violin по 4 ключевым метрикам
`03_correlation_heatmap.png`	heatmap корреляций
`04_shap_summary.png`	SHAP summary (лучший ансамбль)
`05_h2_group_importance.png`	Σ|SHAP| по блокам для H2
`ru_h1_metrics.csv`	train/test ROC/PR + Δ по всем трём моделям
`ru_shap_feature_importance.csv`	mean |SHAP| по фичам
`ru_shap_group_importance.csv`	суммы по блокам
`ru_correlation_matrix.csv`, `ru_feature_stats.csv`, `ru_medians_by_class.csv`	EDA-таблицы
`ru_summary.md`	готовый текст с вердиктами H1 и H2 — можно вставить в §3.2–3.3

Всё это — вход для Stage-2 (PIT) и для сравнения с Китаем.